



GUÍA PROFESIONAL

ROADMAP AI ENGINEER

De los fundamentos a los sistemas de IA en producción

Incluye contenidos técnicos, relación con materias de Ingeniería UTN, proyectos por nivel, tecnologías y cuatro libros clave para cada etapa.

12

niveles progresivos

UTN

materias relacionadas

48

libros recomendados

6

proyectos de portfolio



¿Qué hace un AI Engineer?

Integra modelos, datos y software para construir productos de IA confiables.

Definición del rol

Un AI Engineer no se limita a entrenar modelos. Convierte capacidades de machine learning y modelos generativos en aplicaciones reales: prepara datos, integra APIs, construye RAG y agentes, evalúa calidad, controla costos, despliega servicios y mantiene el sistema en producción.

1

Programación

Python, Git, Linux, APIs y pruebas.

2

Datos y modelos

SQL, ML, deep learning y transformers.

3

RAG y agentes

Recuperación, herramientas, memoria y control.

4

Producción

Docker, CI/CD, cloud, MLOps y observabilidad.

5

Evaluación

Datasets de prueba, métricas y regresiones.

6

Seguridad

Privacidad, permisos, guardrails y auditoría.

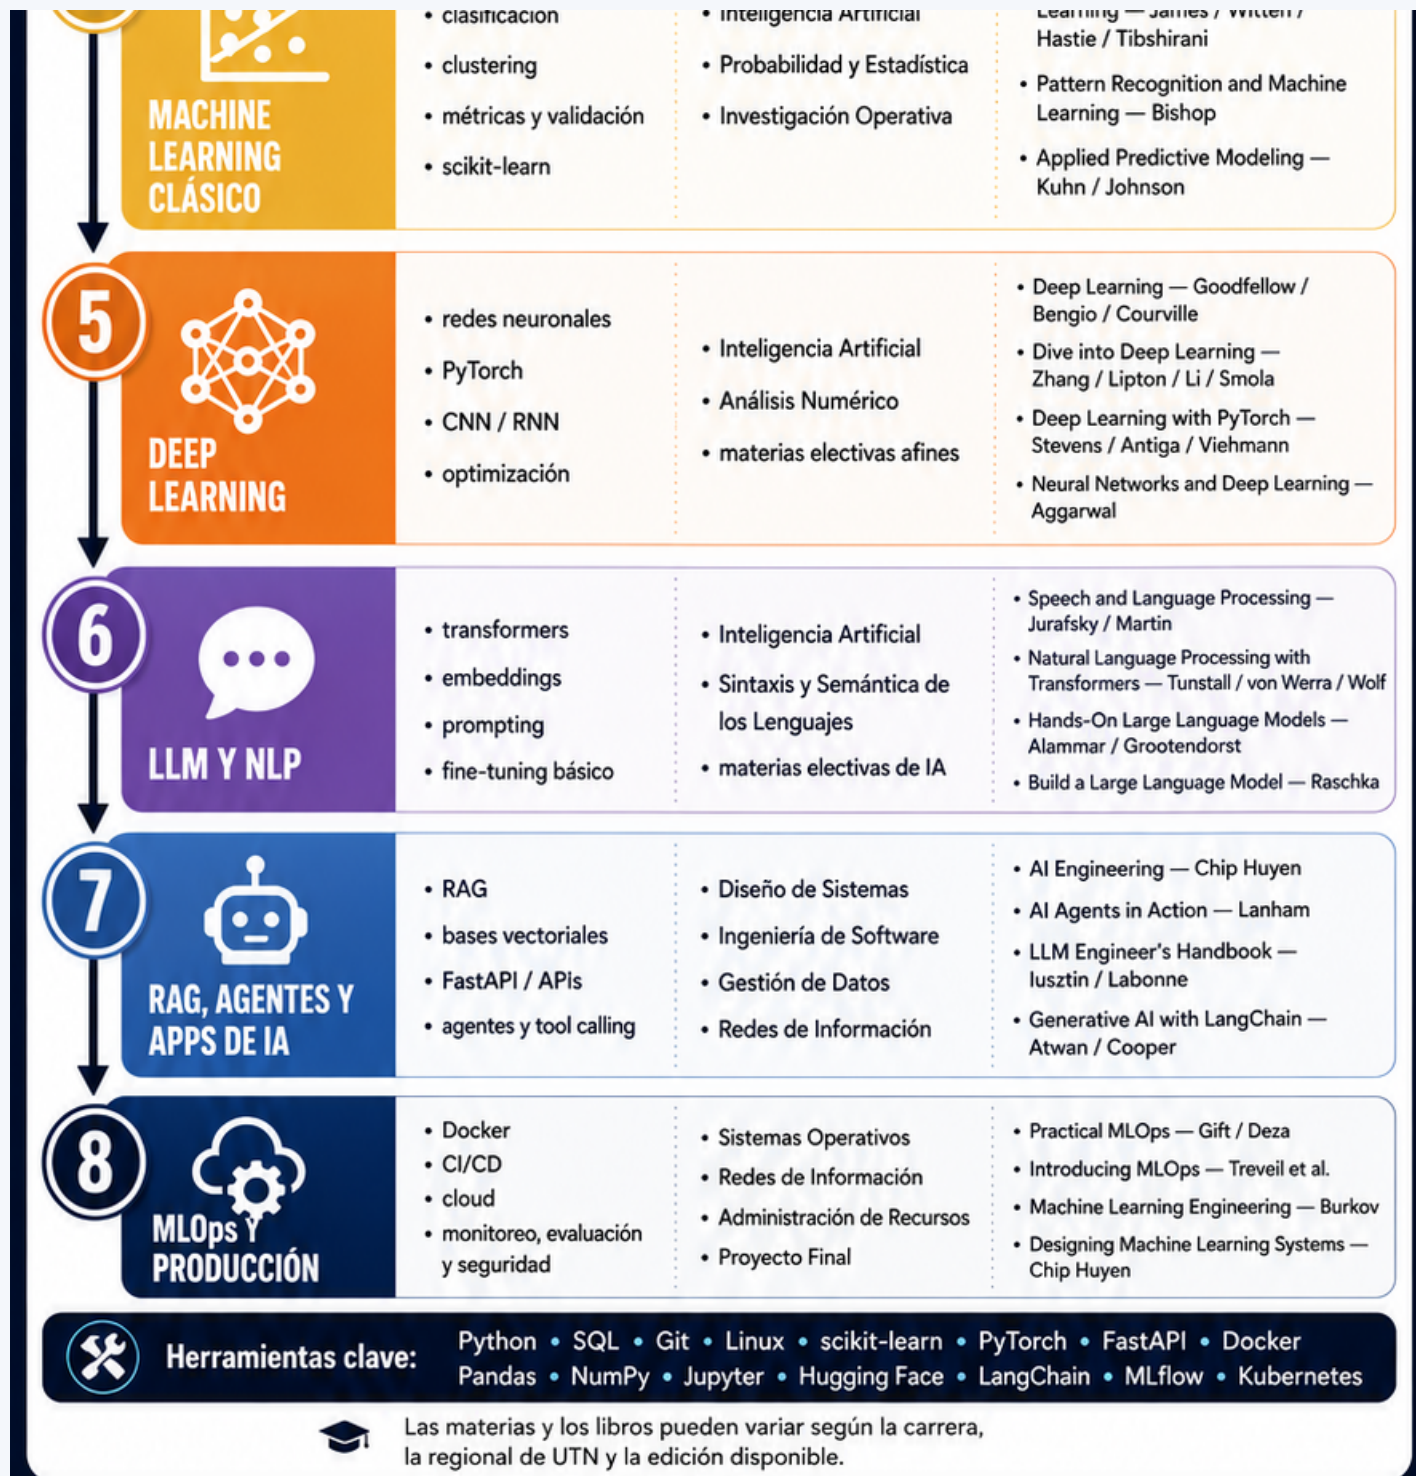
Ciclo profesional completo



ROADMAP AI ENGINEER

De lo básico a lo avanzado + materias de Ingeniería UTN relacionadas + libros clave

	Aprender	Materias UTN relacionadas	4 libros clave
1  FUNDAMENTOS DE PROGRAMACIÓN	• Python • Git y GitHub • Linux / terminal • lógica y estructuras básicas	• Algoritmos y Estructuras de Datos • Sistemas y Organizaciones • Arquitectura de Computadoras	• Python Crash Course — Matthes • Automate the Boring Stuff — Sweigart • Pro Git — Chacon / Straub • The Linux Command Line — Shotts
2  MATEMÁTICA Y ESTADÍSTICA	• álgebra lineal • cálculo • probabilidad • estadística	• Álgebra y Geometría Analítica • Análisis Matemático I • Análisis Matemático II • Probabilidad y Estadística • Matemática Discreta	• Linear Algebra and Its Applications — Lay • Calculus — Stewart • Introduction to Probability — Blitzstein / Hwang • Practical Statistics for Data Scientists — Bruce / Bruce / Gedeck
3  DATOS Y BASES DE DATOS	• SQL • modelado de datos • ETL / limpieza de datos • Pandas y análisis exploratorio	• Gestión de Datos • Bases de Datos • Desarrollo de Software	• Learning SQL — Beaulieu • Database System Concepts — Silberschatz / Korth / Sudarshan • Designing Data-Intensive Applications — Kleppmann • Python for Data Analysis — McKinney
4  MACHINE	• regresión • clasificación • clustering • métricas y validación	• Inteligencia Artificial • Probabilidad y Estadística • Investigación Operativa	• Hands-On Machine Learning — Géron • An Introduction to Statistical Learning — James / Witten / Hastie / Tibshirani • Pattern Recognition and Machine Learning — Bishop



Contenido y forma de uso

Avance secuencial: cada nivel termina con un proyecto y una selección de libros.

Índice

Resumen del rol	2
Roadmap visual	3
Nivel 1 - Fundamentos de programación	6
Nivel 2 - Matemática, estadística y datos	7
Nivel 3 - Machine Learning tradicional	8
Nivel 4 - Deep Learning	9
Nivel 5 - NLP, transformers y LLM	10
Nivel 6 - RAG y recuperación	11
Nivel 7 - Agentes de IA	12
Nivel 8 - Aplicaciones de IA	13
Nivel 9 - MLOps y LLMOps	14
Nivel 10 - Evaluación profesional	15
Nivel 11 - Seguridad y gobernanza	16
Nivel 12 - Especialización avanzada	17
Matriz de tecnologías	18
Orden de aprendizaje	19
Portfolio mínimo	20
Plan orientativo de 12 meses	21
Fuentes y referencias	22

Cómo estudiar con este documento

- No avances por herramientas aisladas: construye fundamentos y luego integra sistemas.
- Completa el proyecto de cada nivel antes de pasar al siguiente.
- Usa las materias UTN como apoyo conceptual; los nombres varían por carrera y regional.
- Selecciona uno o dos libros por etapa y combínalos con práctica y documentación oficial.

OBJETIVO Escribir software mantenible en Python, versionarlo con Git y operar con comodidad en Linux.

Qué aprender

- Variables, tipos, operadores, condicionales y bucles.
- Funciones, módulos y estructuras: listas, diccionarios, conjuntos y tuplas.
- Programación orientada a objetos, excepciones y lectura de JSON/CSV.
- Entornos virtuales, paquetes, type hints, asincronía y pruebas unitarias.
- Git: ramas, pull requests, conflictos, etiquetas y GitHub Actions.
- Linux: permisos, procesos, servicios, SSH, variables de entorno, logs y Bash.

Tecnologías y herramientas

- Python
- NumPy
- Pandas
- Matplotlib
- scikit-learn
- Pydantic
- HTTPX / Requests
- pytest
- Git / GitHub
- Linux / Bash

Materias UTN relacionadas

- Algoritmos y Estructuras de Datos
- Arquitectura de Computadoras
- Sistemas y Organizaciones
- Paradigmas de Programación

Proyecto del nivel

Aplicación que importe un CSV, limpie datos, genere estadísticas y gráficos, guarde resultados, incluya pruebas automatizadas y se publique en GitHub.

4 libros clave

- Python Crash Course - Eric Matthes
- Automate the Boring Stuff with Python - Al Sweigart
- Pro Git - Scott Chacon / Ben Straub
- The Linux Command Line - William Shotts

OBJETIVO

Interpretar qué ocurre dentro de los modelos y preparar datos confiables para entrenamiento y análisis.

Qué aprender

- Álgebra lineal: vectores, matrices, productos, espacios, autovalores, SVD y similitud coseno.
- Cálculo: derivadas, derivadas parciales, gradiente, regla de la cadena y optimización.
- Probabilidad y estadística: distribuciones, Bayes, muestreo, intervalos, hipótesis, sesgo y varianza.
- SQL: modelo relacional, claves, JOIN, GROUP BY, subconsultas, ventanas, índices y transacciones.
- Limpieza, transformación, normalización y procesos ETL/ELT.
- Tipos de datos: tabulares, texto, imágenes, audio, series temporales y documentos.

Tecnologías y herramientas

- NumPy
- Pandas
- PostgreSQL
- Jupyter
- Matplotlib
- SQL
- ETL / ELT

Materias UTN relacionadas

- Álgebra y Geometría Analítica
- Análisis Matemático I y II
- Probabilidad y Estadística
- Matemática Discreta
- Gestión de Datos

Proyecto del nivel

Crear una base PostgreSQL, cargar y depurar información con Pandas y elaborar un análisis exploratorio que responda preguntas concretas.

4 libros clave

- Linear Algebra and Its Applications - David C. Lay
- Calculus - James Stewart
- Introduction to Probability - Blitzstein / Hwang
- Practical Statistics for Data Scientists - Bruce / Bruce / Gedeck

OBJETIVO Construir líneas base sólidas y seleccionar modelos según el problema y la métrica correcta.

Qué aprender

- Aprendizaje supervisado y no supervisado; clasificación, regresión y clustering.
- División de entrenamiento, validación y prueba; validación cruzada y ajuste de hiperparámetros.
- Sobreajuste, subajuste, regularización, fuga de datos y clases desbalanceadas.
- Algoritmos: regresión lineal/logística, KNN, árboles, Random Forest, boosting, SVM, K-means y PCA.
- Métricas de clasificación: precision, recall, F1, ROC-AUC, PR-AUC y matriz de confusión.
- Métricas de regresión: MAE, MSE, RMSE y R^2 .

Tecnologías y herramientas

- scikit-learn
- XGBoost / LightGBM
- Pandas
- NumPy
- Matplotlib
- Jupyter

Materias UTN relacionadas

- Inteligencia Artificial
- Probabilidad y Estadística
- Investigación Operativa
- Simulación

Proyecto del nivel

Sistema completo de clasificación o predicción: definición del problema, datos, baseline, comparación de algoritmos, ajuste, evaluación, explicación y API.

4 libros clave

- Hands-On Machine Learning - Aurélien Géron
- An Introduction to Statistical Learning - James et al.
- Pattern Recognition and Machine Learning - Christopher Bishop
- Applied Predictive Modeling - Kuhn / Johnson

OBJETIVO Entrenar redes neuronales y comprender cuándo aportan valor frente a modelos clásicos.

Qué aprender

- Perceptrón, capas densas, funciones de activación y funciones de pérdida.
- Forward pass, backpropagation, optimizadores, batch, epoch y learning rate.
- Regularización, dropout, batch normalization e inicialización de pesos.
- Arquitecturas: redes densas, CNN, RNN, LSTM, GRU, autoencoders y atención.
- PyTorch: tensores, autograd, Dataset, DataLoader, bucles de entrenamiento y checkpoints.
- GPU/CUDA, transfer learning y comparación con modelos tradicionales.

Tecnologías y herramientas

- PyTorch
- CUDA
- torchvision
- TensorBoard / MLflow
- NumPy

Materias UTN relacionadas

- Inteligencia Artificial
- Análisis Numérico
- Procesamiento de Señales
- Electivas de IA

Proyecto del nivel

Entrenar una red para imágenes, texto, anomalías o series temporales e incluir una comparación cuantitativa con una línea base clásica.

4 libros clave

- Deep Learning - Goodfellow / Bengio / Courville
- Dive into Deep Learning - Zhang et al.
- Deep Learning with PyTorch - Stevens / Antiga / Viehmann
- Neural Networks and Deep Learning - Charu Aggarwal

OBJETIVO

Comprender transformers y crear aplicaciones LLM con salidas controladas, costos medidos y pruebas.

Qué aprender

- NLP clásico: normalización, tokenización, stemming, lematización, n-gramas, BoW y TF-IDF.
- Clasificación de texto, entidades, búsqueda semántica y embeddings.
- Transformers: atención, encoder, decoder, posiciones, ventana de contexto y generación autorregresiva.
- Prompting: system prompts, few-shot, temperatura, sampling y salidas estructuradas.
- Function calling, streaming, manejo de contexto, conteo de tokens, rate limits y reintentos.
- Selección entre modelos alojados y locales según calidad, costo, privacidad y latencia.

Tecnologías y herramientas

- Transformers
- Hugging Face
- APIs de modelos
- Tokenizers
- Accelerate
- PyTorch

Materias UTN relacionadas

- Inteligencia Artificial
- Sintaxis y Semántica de los Lenguajes
- Procesamiento de Lenguaje Natural
- Electivas de IA

Proyecto del nivel

Asistente que clasifique intención, devuelva JSON válido, utilice una herramienta externa y registre tokens, latencia, errores y costo estimado.

4 libros clave

- Speech and Language Processing - Jurafsky / Martin
- Natural Language Processing with Transformers - Tunstall et al.
- Hands-On Large Language Models - Alamar / Grootendorst
- Build a Large Language Model (From Scratch) - Sebastian Raschka

OBJETIVO Construir sistemas RAG que recuperen evidencia relevante, citen fuentes y reconozcan falta de información.

Qué aprender

- Ingesta de PDF, Word, HTML y CSV; limpieza, metadatos, tablas e imágenes.
- Chunking: tamaño, solapamiento, jerarquía y trazabilidad del fragmento.
- Embeddings, similitud coseno, búsqueda vectorial, BM25 y búsqueda híbrida.
- Filtros por metadatos, reranking y selección de contexto.
- Bases vectoriales: pgvector, Qdrant, Weaviate, Milvus o servicios gestionados.
- Evaluación separada de recuperación, contexto, fidelidad, citas, latencia y costo.

Tecnologías y herramientas

- pgvector
- Qdrant
- Weaviate / Milvus
- BM25
- Rerankers
- Procesamiento documental

Materias UTN relacionadas

- Gestión de Datos
- Bases de Datos
- Recuperación de Información
- Diseño de Sistemas

Proyecto del nivel

RAG documental con múltiples PDF, embeddings, índice vectorial, búsqueda híbrida, citas, respuesta “no hay evidencia” y evaluación automática/manual.

4 libros clave

- AI Engineering - Chip Huyen
- Designing Machine Learning Systems - Chip Huyen
- Generative AI with LangChain - Ben Auffarth
- Hands-On Large Language Models - Alammur / Grootendorst

OBJETIVO Diseñar agentes útiles sin perder control, trazabilidad ni supervisión humana.

Qué aprender

- Tool calling, planificación, memoria y estado.
- Ciclos de razonamiento y acción, routing, delegación y patrones supervisor-trabajadores.
- Herramientas síncronas/asíncronas, APIs, bases de datos, MCP y conectores.
- Human-in-the-loop, confirmación antes de acciones sensibles y límites de autonomía.
- Trazabilidad de decisiones, auditoría y condiciones de detención.
- Diferenciar flujos deterministas de agentes dinámicos y usar cada patrón donde corresponde.

Tecnologías y herramientas

- SDK de agentes
- MCP
- APIs
- Colas asíncronas
- Trazas y observabilidad
- RAG

Materias UTN relacionadas

- Diseño de Sistemas
- Ingeniería de Software
- Inteligencia Artificial
- Sistemas Distribuidos

Proyecto del nivel

Agente que consulte documentos y bases, llame una API, genere un informe, solicite aprobación antes de modificar datos y registre cada acción.

4 libros clave

- AI Agents in Action - Micheal Lanham
- AI Engineering - Chip Huyen
- LLM Engineer's Handbook - Iusztin / Labonne
- Building Agentic AI Systems - Anjanava Biswas et al.

OBJETIVO Integrar IA dentro de aplicaciones seguras, escalables y con buena experiencia de usuario.

Qué aprender

- HTTP, APIs REST, WebSockets, autenticación, autorización, JWT y OAuth.
- Validación, manejo de errores, procesos asíncronos, colas, caché y rate limiting.
- Backend con FastAPI/Pydantic, PostgreSQL, Redis y tareas en segundo plano.
- Frontend básico: HTML, CSS, TypeScript, React/Next.js e interfaces de chat.
- Streaming de tokens, carga de archivos, visualización de fuentes e historial.
- Diseño por capas, configuración por entornos y pruebas de integración.

Tecnologías y herramientas

- FastAPI
- Pydantic
- PostgreSQL
- Redis
- Celery / colas
- React / Next.js
- WebSockets

Materias UTN relacionadas

- Diseño de Sistemas
- Ingeniería de Software
- Desarrollo de Software
- Redes de Información

Proyecto del nivel

Aplicación completa con autenticación, frontend, backend, base de datos, chat con streaming, RAG, historial y panel de métricas.

4 libros clave

- Building Machine Learning Powered Applications - Emmanuel Ameisen
- Designing Web APIs - Brenda Jin et al.
- Architecture Patterns with Python - Percival / Gregory
- Building Data Science Applications with FastAPI - François Voron

OBJETIVO Pasar de un prototipo a un servicio reproducible, escalable y operable.

Qué aprender

- Docker, Dockerfile, Compose, redes, volúmenes, variables y secretos.
- Kubernetes básico: deployments, services, escalado, balanceo y recursos CPU/GPU.
- CI/CD: pruebas, linting, imágenes, versiones, despliegue automático y rollback.
- Infraestructura como código con Terraform y automatización con Ansible.
- Experimentos, datasets, modelos, linaje, Model Registry y promoción entre entornos.
- Observabilidad: latencia, tokens, costo, errores, calidad, drift, satisfacción y trazas.

Tecnologías y herramientas

- Docker
- Kubernetes
- GitHub Actions / GitLab CI
- Terraform
- Ansible
- MLflow
- Cloud

Materias UTN relacionadas

- Sistemas Operativos
- Redes de Información
- Administración de Recursos
- Sistemas Distribuidos
- Proyecto Final

Proyecto del nivel

Pipeline reproducible que entrene o integre un modelo, ejecute pruebas, construya una imagen, despliegue, registre métricas y permita rollback.

4 libros clave

- Practical MLOps - Noah Gift / Alfredo Deza
- Machine Learning Engineering - Andriy Burkov
- Introducing MLOps - Mark Treveil et al.
- Designing Machine Learning Systems - Chip Huyen

OBJETIVO Convertir criterios subjetivos en pruebas reproducibles para modelos, RAG y agentes.

Qué aprender

- Datasets de evaluación con casos normales, extremos y adversariales.
- Respuestas esperadas, rúbricas, umbrales y criterios de aprobación.
- Métricas deterministas, comparación exacta, evaluación semántica y humana.
- LLM como evaluador, comparación por pares y pruebas A/B.
- Evaluación de herramientas, recuperación y trayectorias de agentes.
- Pruebas de regresión ante cambios de modelo, prompt, chunking, embedding o flujo.

Tecnologías y herramientas

- Evals
- Experimentos A/B
- Rúbricas
- Datasets de prueba
- Trazas
- Dashboards

Materias UTN relacionadas

- Probabilidad y Estadística
- Ingeniería de Software
- Calidad de Software
- Métodos Numéricos

Proyecto del nivel

Suite de evaluación que compare versiones de un sistema RAG o agente y bloquee el despliegue si disminuye calidad, seguridad o eficiencia.

4 libros clave

- Reliable Machine Learning - Chen et al.
- Evaluating Machine Learning Models - Alice Zheng
- Trustworthy Online Controlled Experiments - Kohavi et al.
- AI Engineering - Chip Huyen

OBJETIVO Reducir riesgos tradicionales y específicos de aplicaciones LLM y agentes.

Qué aprender

- Gestión de secretos, cifrado, HTTPS, autenticación, autorización y mínimo privilegio.
- Validación de entradas, auditoría, dependencias y protección de datos personales.
- Prompt injection directa e indirecta, fuga de información y salidas inseguras.
- Envenenamiento de datos, abuso de herramientas, costos descontrolados y exceso de autonomía.
- Allow-lists, validación de argumentos, sanitización, sandboxing y confirmación humana.
- Red teaming, filtros de datos sensibles, logs de auditoría y gobernanza del ciclo de vida.

Tecnologías y herramientas

- OWASP GenAI
- Gestores de secretos
- IAM
- Sandboxing
- Auditoría
- Red teaming
- Guardrails

Materias UTN relacionadas

- Seguridad en Sistemas
- Legislación / Ética profesional
- Ingeniería de Software
- Redes de Información

Proyecto del nivel

Evaluación de amenazas de una aplicación RAG/agente, con matriz de riesgos, pruebas de prompt injection, controles de permisos y registro de auditoría.

4 libros clave

- Threat Modeling: Designing for Security - Adam Shostack
- Security Engineering - Ross Anderson
- Adversarial Machine Learning - Joseph et al.
- Weapons of Math Destruction - Cathy O'Neil

OBJETIVO Optimizar modelos y sistemas para necesidades especializadas de calidad, costo y rendimiento.

Qué aprender

- Fine-tuning supervisado, datasets, LoRA/PEFT, DPO, preferencias y modelos de recompensa.
- Evaluación antes/después del ajuste, distillation y selección de datos.
- Cuantización, pruning, batching, caché KV, prompt caching y speculative decoding.
- Servidores de inferencia, throughput, latencia y uso eficiente de GPU.
- Paralelismo de datos, tensorial, de pipeline y modelo; mixed precision y checkpoints.
- IA multimodal: visión-lenguaje, OCR, voz, audio, imágenes, video y document intelligence.

Tecnologías y herramientas

- PEFT / LoRA
- TRL
- vLLM / servidores de inferencia
- CUDA
- Clusters GPU
- Frameworks multimodales

Materias UTN relacionadas

- Inteligencia Artificial avanzada
- Arquitectura de Computadoras
- Computación Paralela
- Procesamiento de Señales
- Proyecto Final

Proyecto del nivel

Especialización a elegir: ajuste eficiente de un LLM, servidor de inferencia optimizado, sistema multimodal o entrenamiento distribuido con medición de rendimiento.

4 libros clave

- Efficient Processing of Deep Neural Networks - Sze et al.
- Programming Massively Parallel Processors - Kirk / Hwu
- Build a Large Language Model (From Scratch) - Raschka
- Deep Learning - Goodfellow / Bengio / Courville

Matriz de tecnologías

Herramientas frecuentes por área. Domina principios antes que marcas.

Área	Tecnologías principales
Programación	Python, SQL, Bash, TypeScript básico
Datos	Pandas, NumPy, PostgreSQL, ETL/ELT
Machine Learning	scikit-learn, XGBoost, LightGBM
Deep Learning	PyTorch, CUDA, transfer learning
LLM / NLP	Transformers, Hugging Face, APIs de modelos
RAG	Embeddings, pgvector, Qdrant, BM25, reranking
Backend	FastAPI, Pydantic, PostgreSQL, Redis, colas
Agentes	Tool calling, MCP, SDK de agentes, trazas
MLOps	MLflow, Docker, CI/CD, Kubernetes
Infraestructura	Linux, cloud, Terraform, Ansible
Observabilidad	Logs, métricas, trazas, evaluaciones, costos
Seguridad	OWASP GenAI, secretos, IAM, guardrails, auditoría

Criterio de selección

Elige herramientas por requisitos de calidad, costo, privacidad, latencia, compatibilidad y capacidad del equipo. Las tecnologías cambian; los fundamentos de arquitectura, evaluación y seguridad permanecen.

Orden de aprendizaje recomendado

La secuencia prioriza dependencias: software y datos antes de sistemas generativos avanzados.



Regla práctica

No es necesario esperar a “terminar toda la teoría”. En cada etapa combina 30-40 % de estudio conceptual con 60-70 % de práctica y proyectos verificables.

Portfolio mínimo para demostrar el perfil

Seis proyectos integrados son más valiosos que decenas de notebooks aislados.

01

Datos + ML

Clasificación o predicción con limpieza, validación, métricas y explicación.

TECNOLOGÍAS: scikit-learn, Pandas, PostgreSQL

02

Deep Learning

Imágenes, texto o series temporales con comparación contra una línea base.

TECNOLOGÍAS: PyTorch, CUDA, MLflow

03

Aplicación LLM

Salida estructurada, function calling, streaming, costos y pruebas.

TECNOLOGÍAS: FastAPI, API de modelo, Pydantic

04

Sistema RAG

Documentos, búsqueda híbrida, citas, reranking y evaluación.

TECNOLOGÍAS: pgvector/Qdrant, embeddings, BM25

05

Agente controlado

Herramientas, estado, aprobación humana, trazas y límites.

TECNOLOGÍAS: SDK de agentes, MCP, auditoría

06

Producción completa

API, Docker, base, CI/CD, observabilidad, seguridad y rollback.

TECNOLOGÍAS: Docker, GitHub Actions, cloud, MLflow

Plan orientativo de 12 meses

Ejemplo intensivo para una persona con base universitaria y 10-15 horas semanales.

Meses 1-2

Fundamentos

Python, Git, Linux, SQL y proyecto de datos.

Meses 3-4

Matemática + ML

Estadística aplicada, scikit-learn y primer modelo completo.

Meses 5-6

Deep Learning

PyTorch, entrenamiento, GPU y proyecto de redes neuronales.

Meses 7-8

LLM + RAG

Transformers, prompting, embeddings, búsqueda híbrida y citas.

Meses 9-10

Agentes + Apps

Tool calling, FastAPI, frontend, memoria y aprobación humana.

Producción

Ajuste según experiencia

Con experiencia en software, reduce la etapa inicial y profundiza MLOps y arquitectura. Con formación matemática, acelera los niveles 2-4. Sin experiencia previa, extiende el plan a 18-24 meses.

Fuentes y referencias técnicas

Documentación oficial citada en el documento original y conservada en esta edición.

1

PyTorch Tutorials

<https://docs.pytorch.org/tutorials/index.html>

2

Hugging Face Transformers

<https://huggingface.co/docs/transformers/index>

3

OpenAI Platform - Retrieval

<https://platform.openai.com/docs/guides/retrieval>

4

OpenAI Platform - Agents

<https://platform.openai.com/docs/guides/agents>

5

FastAPI - Deployment

<https://fastapi.tiangolo.com/deployment/>

6

Kubernetes - Overview

<https://kubernetes.io/docs/concepts/overview/>

7

MLflow - Model Registry

<https://mlflow.org/docs/latest/ml/model-registry/>

8

OpenAI Platform - Evals

<https://platform.openai.com/docs/guides/evals>

9

OpenAI Platform - Model optimization

<https://platform.openai.com/docs/guides/fine-tuning>

10

OWASP Top 10 for LLM Applications

<https://owasp.org/www-project-top-10-for-large-language-model-applications/>

11

Hugging Face - Fine-tuning

<https://huggingface.co/docs/transformers/training>

12

Hugging Face - LLM inference optimization

https://huggingface.co/docs/transformers/v4.44.1/llm_optims

Nota académica

Las asignaturas UTN mencionadas son relaciones orientativas. Su denominación y profundidad pueden variar entre Ingeniería en Sistemas de Información, Ingeniería Electrónica, Ingeniería Industrial y otras carreras, así como entre regionales y planes de estudio.