

El ecosistema Apache

Cassandra, Hadoop y Spark, y su relación con Infraestructura y Operaciones (I&O)

Este documento explica qué es la Apache Software Foundation y tres de sus herramientas más usadas en entornos de datos a gran escala —Cassandra, Hadoop y Spark—, detallando para qué sirve cada una y de qué manera se relacionan con el área de Infraestructura y Operaciones (I&O), encargada de desplegarlas, mantenerlas disponibles y garantizar su buen funcionamiento en producción.

1. ¿Qué es Apache?

El nombre **Apache** se usa en dos sentidos distintos, y ambos son relevantes en infraestructura:

- **Apache Software Foundation (ASF):** organización sin fines de lucro, fundada en 1999, que aloja y da soporte legal/administrativo a cientos de proyectos de código abierto. Cassandra, Hadoop y Spark son todos proyectos *de* esta fundación —por eso llevan el prefijo “Apache” en su nombre oficial.
- **Apache HTTP Server:** el proyecto original de 1995, un servidor web usado para alojar sitios y responder peticiones HTTP/HTTPS. Es distinto de los tres sistemas de datos que se explican a continuación, aunque comparte el mismo origen (la fundación).

En resumen: cuando en un contexto de infraestructura se menciona “Apache X”, casi siempre significa software libre, de código abierto, mantenido por la comunidad, con soporte empresarial indirecto a través de distribuciones (por ejemplo Cloudera o Databricks).

2. Las tres herramientas

Apache Cassandra — base de datos NoSQL distribuida

Alta disponibilidad, sin punto único de falla, escalado horizontal por nodos.

Para qué sirve

- Arquitectura peer-to-peer: todos los nodos son iguales, sin nodo maestro único.
- Escalabilidad horizontal: se agregan más nodos en lugar de agrandar un servidor.
- Replicación automática de datos entre nodos y centros de datos.
- Optimizada para escrituras muy rápidas y grandes volúmenes (mensajería, IoT, series temporales).

Relación con Infraestructura y Operaciones

- Gestión de clústeres distribuidos: múltiples nodos, red y balanceo de carga.
- Monitoreo de latencia, uso de disco, compactaciones y salud de nodos.
- Planificación de capacidad a medida que crece el volumen de datos.
- Recuperación ante desastres gracias a la replicación multi-datacenter.

Apache Hadoop — almacenamiento y procesamiento batch de Big Data

HDFS (almacenamiento distribuido) + MapReduce (procesamiento) + YARN (recursos).

Para qué sirve

- **HDFS:** sistema de archivos distribuido que parte y replica los datos entre nodos.
- **MapReduce:** modelo de programación para procesar datos en paralelo por bloques.
- **YARN:** gestiona los recursos del clúster (CPU, memoria) y programa las tareas.
- Casos de uso: procesamiento batch de logs, data warehousing, ETL, análisis histórico.

Relación con Infraestructura y Operaciones

- Aprovisionamiento y mantenimiento de clústeres grandes (decenas a miles de nodos).
- Planificación de almacenamiento y políticas de replicación de bloques en HDFS.
- Gestión de recursos computacionales vía YARN entre distintos jobs y usuarios.
- Seguridad, autenticación (Kerberos) y auditoría de accesos a los datos.
- Coordinación de actualizaciones del ecosistema (Hive, HBase, etc.) sin downtime.

2. Las tres herramientas (continuación)

Apache Spark — motor de procesamiento distribuido en memoria

Batch, streaming, SQL y machine learning sobre un mismo motor, mucho más rápido que MapReduce.

Para qué sirve

- Procesamiento en memoria (RAM) en lugar de escribir resultados intermedios en disco.
- Soporta procesamiento batch y en tiempo real (Spark Streaming).
- Incluye Spark SQL, MLlib (machine learning) y GraphX (grafos) en un mismo motor.
- Multi-lenguaje: Python (PySpark), Scala, Java o R.
- Casos de uso: ETL a gran escala, entrenamiento de modelos, detección de fraude en tiempo real.

Relación con Infraestructura y Operaciones

- Corre sobre gestores de recursos como YARN, Kubernetes, Mesos o modo standalone.
- Asignación de executors, cores y memoria a cada job, evitando saturar el clúster.
- Monitoreo de rendimiento (tiempos de ejecución, errores de memoria, shuffle de datos).
- Integración con fuentes de almacenamiento: HDFS, S3, Cassandra, bases SQL.
- Auto-scaling en la nube y alta disponibilidad para pipelines críticos de streaming.

3. Comparativa rápida

Herramienta	Rol principal	Enfoque de I&O;
Cassandra	Base de datos NoSQL para operaciones en tiempo real	Alta disponibilidad, replicación multi-datacenter
Hadoop	Almacenamiento (HDFS) + procesamiento batch (MapReduce)	Gestión de almacenamiento distribuido y clústeres grandes
Spark	Motor de procesamiento rápido (batch + streaming + ML)	Gestión de recursos (CPU/memoria) e integración con otras fuentes

En muchos entornos, estas tres herramientas se usan juntas: Hadoop/HDFS o Cassandra como almacenamiento, y Spark como motor de procesamiento sobre esos datos.

4. Por qué le importan a Infraestructura y Operaciones

Ninguna de estas tres herramientas es “liviana”: todas requieren clústeres de varios servidores, monitoreo constante y decisiones de capacidad. Por eso son, en la práctica, piezas de infraestructura crítica —no solo herramientas para desarrolladores. Las responsabilidades típicas de I&O sobre este stack incluyen:

- **Disponibilidad:** evitar caídas de sistemas críticos en producción (24/7).
- **Escalado:** sumar nodos o recursos a medida que crece el volumen de datos.
- **Monitoreo:** métricas de salud, rendimiento y uso de recursos del clúster.
- **Seguridad:** autenticación, permisos y auditoría de accesos a los datos.
- **Continuidad de negocio:** backups, replicación y planes de recuperación ante desastres.
- **Costos:** dimensionamiento de hardware o instancias cloud según la carga real.

Documento generado como resumen explicativo del ecosistema Apache (Cassandra, Hadoop, Spark) y su vínculo con Infraestructura y Operaciones.